

lista 4 - descritiva

Lista 4 - Estatística Descritiva

Professora: Márcia D'Elia Branco

Nomes:

Bruna Umino

Beatriz Vianna

Questão 1

```
UPM <- c(100, 100, 125, 125, 150, 150, 175, 175, 200, 200, 225, 225)
clientes <- c(30, 44, 114, 138, 155, 163, 145, 163, 158, 126, 126, 106)
```

1a


```
lm(clientes~UPM)
```

```
##
## Call:
## lm(formula = clientes ~ UPM)
##
## Coefficients:
## (Intercept)          UPM
##    40.9905         0.5006
```

1b

```
modelo1 <- lm(clientes~UPM)
plot(UPM, clientes, xlab = "UPM", ylab = "número de clientes", main="Gráfico de dispersão com reta ajustada",
abline(modelo1)
```

Gráfico de dispersão com reta ajustada



Como podemos observar, a reta ajustada não é o melhor modelo para ajustar os dados, pois não se comportam linearmente


1c

```
plot(clientes~UPM, xlab = "UPM", ylab = "número de clientes", main="Gráfico de dispersão com parábola a
modelo1 <- lm(clientes~UPM)
modelo2 <- update(modelo1,.~. +I(UPM^2))
anova(modelo1,modelo2)

## Analysis of Variance Table
##
## Model 1: clientes ~ UPM
## Model 2: clientes ~ UPM + I(UPM^2)
##   Res.Df    RSS Df Sum of Sq   F    Pr(>F)
## 1      10 15949.4
## 2       9  2377.4  1    13572 51.379 5.263e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


#abline(modelo1)
cf.m2 <- coef(modelo2)
curve(cf.m2[1]+cf.m2[2]*x+cf.m2[3]*x^2, add=T, lty=2)
```

Gráfico de dispersão com parábola ajustada



```
residuos <- residuals(modelo2)
plot(residuos,
     ylab="Resíduos",
     xlab="UPM + I(UPM^2)",
     main="Gráfico de resíduos")
abline(0,0)
```

Gráfico de resíduos



Observando o gráfico, podemos ver que mesmo com o aumento o valor do eixo x, não aumenta a variabilidade dos dados, então o gráfico é homocedástico.

Questão 2

```
distancia <- c(6.25, 12.5, 25.0, 50.0, 100.0)
primeiro <- c(5, 5, 4, 3, 1)
segundo <- c(3,2,5,4,2)
terceiro <- c(4,5,3,2,2)
quarto <- c(6,4,0,2,3)
medias <- c(0,0,0,0,0)


tabela <- data.frame (distancia, primeiro, segundo, terceiro, quarto)
medias <- c(rowMeans (tabela[,2:5]))
tabela$medias <- medias
tabela
```

##	distancia	primeiro	segundo	terceiro	quarto	medias
## 1	6.25	5	3	4	6	4.50
## 2	12.50	5	2	5	4	4.00
## 3	25.00	4	5	3	0	3.00
## 4	50.00	3	4	2	2	2.75
## 5	100.00	1	2	2	3	2.00

Pela tabela, é possível notar que existe uma relação entre a distância das moscas e a média de moscas capturadas (a medida que uma aumenta, a outra diminui). Iremos ajustar uma reta para verificar se essa relação é linear:

```
plot (tabela$medias~tabela$distancia,
      xlab="distancia entre as moscas e a armadilha",
      ylab="media de moscas capturadas",
      main="gráfico de dispersão com reta de regressão")
abline (lm(tabela$medias~tabela$distancia))
```

gráfico de dispersão com reta de regressão




Ao observar o gráfico obtido e a relação entre os pontos e a reta de regressão, é fácil ver sem mais cálculos que a dispersão dos pontos não é linear, e parece aproximar-se de uma parábola. Fazemos o gráfico a seguir:

```
plot(tabela$medias~tabela$distancia, xlab = "distancia entre as moscas e a armadilha", ylab = "media de
modelo1 <- lm(tabela$medias~tabela$distancia)
modelo2 <- update(modelo1,.~. +I(tabela$distancia^2))
anova(modelo1,modelo2)
```

```
## Analysis of Variance Table
##
## Model 1: tabela$medias ~ tabela$distancia
## Model 2: tabela$medias ~ tabela$distancia + I(tabela$distancia^2)
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1      3 0.67297
## 2      2 0.23948  1   0.43348 3.6201 0.1974

cf.m2 <- coef(modelo2)
curve(cf.m2[1]+cf.m2[2]*x+cf.m2[3]*x^2, add=T, lty=2)
```

Gráfico de dispersão com parábola ajustada



Esta distribuição parece mais próxima do gráfico de dispersão com parábola ajustada. Temos que estar atentos ao fato de que há apenas cinco observações, portanto é difícil chegar a dados conclusivos sobre o modelo. O que pode-se dizer é que existe uma relação entre a distância da armadilha e a quantidade de moscas capturadas, e que esta relação parece ser quadrática.

Questão 3

10	11	12	13	14
-2	26	-2	0	-4
0	-4	-6	4	0
-4	-2	2	-2	-4
12	-6	8	0	4
-2	2	-2	-4	-6
		2		-2

A partir da análise dos valores dos resíduos, é possível notar muitos valores negativos, mais próximos de zero, alguns positivos próximos de zero também e uns poucos positivos mais distantes de zero, como 12 e principalmente 26. Este valor, 26, está muito distante da reta de regressão linear em comparação a todos os outros, o que é um forte indicativo de que pode ser um vilão. Se esta observação fosse excluída ao se ajustar a reta, esta reta ficaria um pouco mais para baixo, e os valores de seus resíduos seriam mais próximos de zero.

Questão 4

[illegible]

A partir dos dados podemos observar que a estimativa do intercepto é 2.4040 e do coeficiente angular é -0.3235, ou seja, quanto maior o seu escore no exame psicológico, maior será sua chance de não ter ocorrência de sintomas de demência senil. Além disso, o $\Pr(>|z|)$ mostra os p valores correspondentes aos z values (quociente da estimativa pelo erro padrão) em uma distribuição normal, observando os p valores e pela quantidade de * sabemos que o valor 0.00453 se aproxima mais do centro da normal que o valor 0.04369, ou seja, é mais importante para a análise que o valor dado pelo intercepto. Por fim, o residual deviance apresenta a falta de ajuste do modelo como um todo e o null deviance é a mesma medida reduzida à apenas o intercepto.

Questão 5

```
library(car)
dados <- Duncan
```